

1 Ergodic

Theorem: Let $\mathcal{G} = (V, \mathbf{E}, \mathbf{W})$ be a weighted graph with $|V| = n$ and f be a graph signal defined on \mathcal{G} . Let $\mathcal{H}(f, \mathcal{G}; \tau)$ denote the heavy snow transformation of f . Then there exists a unique stationary distribution $\boldsymbol{\pi}^*$ such that $\boldsymbol{\pi}^0 \prod_{\tau=1}^{\infty} \mathbf{P}^{\tau} = \boldsymbol{\pi}^*$, where \mathbf{P}^{τ} is a transition matrix with the (i, j) th element $P_{ij}^{\tau} = \text{Prob}(v_j = \tilde{v}^{\tau} | v_i = \tilde{v}^{\tau-1})$ and $\boldsymbol{\pi}^0 = (1/n, \dots, 1/n)^{\top}$.

Proof. The necessary conditions for the ergodictiy of \mathbf{P}^{τ} are (i) irreducible and (ii) aperiodic. For (i) irreducible, it is clear due to $\gamma < 1$. To show (ii), suppose that $\text{gcd}\{\tau > 0 : \text{Prob}(\tilde{v}^{\tau} = v | \tilde{v}^0 = u) > 0\} \geq 2$, where gcd denotes the greatest common divisor. For all $v_i \in V$ and $\ell > 0$, P_{ii}^{ℓ} should be 0, contrary to the assumption.

note: P 가 τ 에 따라 변화해도 상관없는지?

Theorem: $\mathcal{G} = (V, \mathbf{E}, \mathbf{W})$ 가 $\max_{i,j} |f(v_i) - f(v_j)| < \infty$ 인 regular graph 라면 모든 고정된 i, j 에 대하여 아래가 성립한다.

$$p_{12}^{\tau} = \frac{W_{12}}{\sum_{j=1}^n W_{1j}} + o(1) \quad \text{for all } i, j.$$

여기에서

$$p_{12}^{\tau} := \text{Prob}(T^{\tau} = 2 | T^{\tau-1} = 1) = \begin{cases} \frac{d(v_2)}{\sum_{i=1}^n d(v_i)} & \mathcal{U}^{\tau-1} = \emptyset \\ \frac{1}{|\mathcal{U}^{\tau-1}|} & \mathcal{U}^{\tau-1} \neq \emptyset \text{ and } v_1 \in \mathcal{U}^{\tau-1} \\ 0 & \mathcal{U}^{\tau-1} \neq \emptyset \text{ and } v_1 \notin \mathcal{U}^{\tau-1} \end{cases}$$

Proof. 아래와 같이 쓰자.

$$p_{12}^{\tau} = a^{\tau} + b^{\tau} + 0$$

$$a^{\tau} = I(\mathcal{U}^{\tau-1} = \emptyset) \times \frac{d(v_2)}{\sum_{i=1}^n d(v_i)} = I(\mathcal{U}^{\tau-1} = \emptyset) \frac{d(v_2)}{d}$$

$$b^{\tau} = I(\mathcal{U}^{\tau-1} \neq \emptyset) I(1 \in \mathcal{U}^{\tau-1}) \times \frac{1}{|\mathcal{U}^{\tau-1}|}$$

그런데 $\frac{I(v_1 \in \mathcal{U}^{\tau-1})}{|\mathcal{U}^{\tau-1}|} = \frac{d(v_1)}{d} + o_p(1)$ 이므로 $b^\tau = I(\mathcal{U}^{\tau-1} \neq \emptyset) \frac{d(v_1)}{d} + o_p(1)$ 이다.
정리하면

$$\begin{aligned} a^\tau &= I(\mathcal{U}^{\tau-1} = \emptyset) \frac{d(v_2)}{d} \\ b^\tau &= I(\mathcal{U}^{\tau-1} \neq \emptyset) \frac{d(v_1)}{d} + o_p(1) \end{aligned}$$

따라서 만약에 $d(v_1) = d(v_2)$ 라면

$$p_{12}^\tau = a^\tau + b^\tau = \frac{d(v_1)}{d} + o_p(1) = \frac{d(v_2)}{d} + o_p(1)$$

그런데 $\frac{d(v_2)}{d} = \frac{W_{12}}{\sum_j W_{1j}}$ 이므로 증명끝.

2 예제2에 대한 백업 (1)

Theorem:

- 빨주노초파남보의 7개의 노드가 있다고 하자. 즉 $V = \{1, 2, 3, \dots, 7\}$ 이라고 하자. 그리고 이들이 서로 링형태로 연결되어 있다고 가정하자.

주장1: : ℓ 시점에서 그림1의 각 지형이 형성될 확률은 모두 같다.

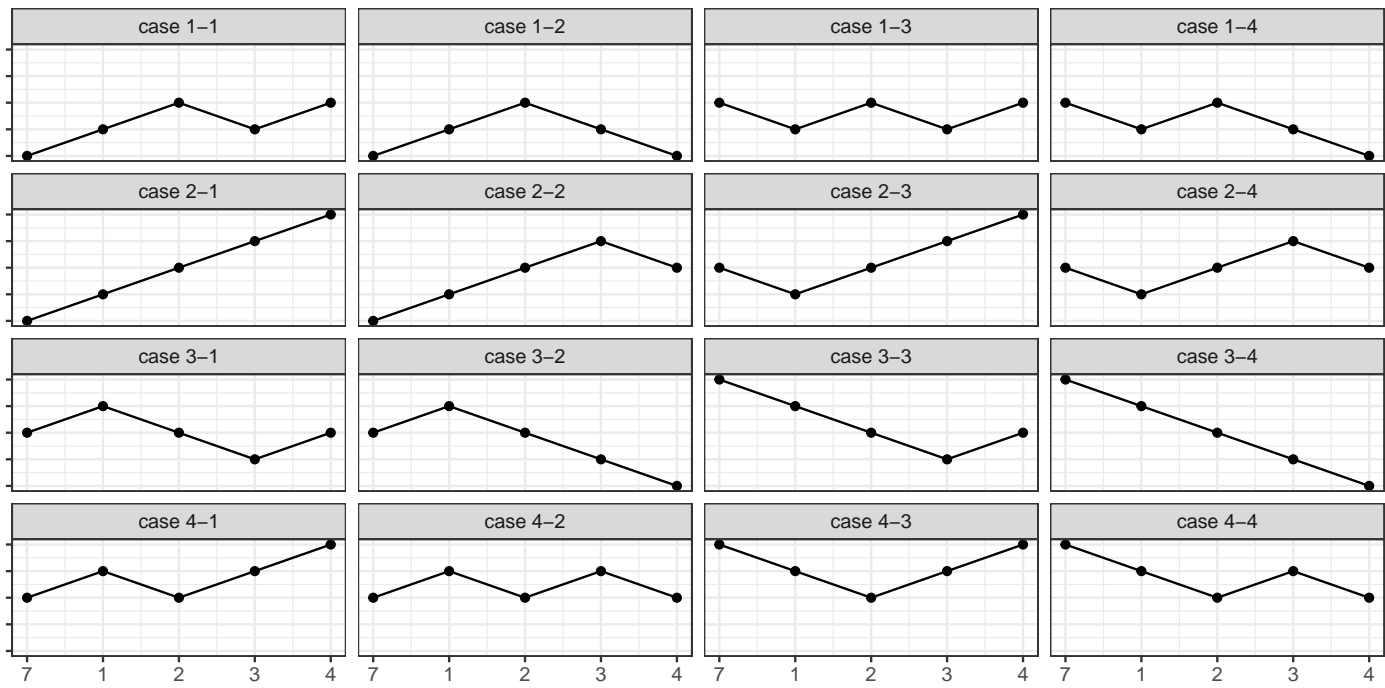


Figure 1: 가능한 지형들의 경우들



주장2: : $\tau = \ell - 1$ 에서 성립한다면 $\tau = \ell$ 에서도 성립한다.

주장2의 증명:

- 아래를 보이면 된다.

$$\Sigma_{13}^\ell - \Sigma_{12}^\ell = \Sigma_{13}^{\ell-1} - \Sigma_{12}^{\ell-1} + (h_1^\ell - h_3^\ell)^2 - (h_1^\ell - h_2^\ell)^2 \geq 0$$

그런데 $\Sigma_{13}^{\ell-1} - \Sigma_{12}^{\ell-1} > 0$ 이므로 아래를 보이면 충분하다.

$$\begin{aligned} A &:= (h_1^\ell - h_3^\ell)^2 - (h_1^\ell - h_2^\ell)^2 \\ &= (h_1^{\ell-1} + \xi_1^\ell - h_3^{\ell-1} - \xi_3^\ell)^2 - (h_1^{\ell-1} + \xi_1^\ell - h_2^{\ell-1} - \xi_2^\ell)^2 \\ &= (h_1^{\ell-1} - h_3^{\ell-1})^2 + (\xi_1^\ell - \xi_3^\ell)^2 - 2(h_1^{\ell-1} - h_3^{\ell-1})(\xi_1^\ell - \xi_3^\ell) \\ &\quad - (h_1^{\ell-1} - h_2^{\ell-1})^2 - (\xi_1^\ell - \xi_2^\ell)^2 + 2(h_1^{\ell-1} - h_2^{\ell-1})(\xi_1^\ell - \xi_2^\ell) \geq 0 \end{aligned}$$

그런데

$$(h_1^{\ell-1} - h_3^{\ell-1})^2 - (h_1^{\ell-1} - h_2^{\ell-1})^2 \geq 0$$

이므로 아래만 보이면 된다.

$$(\xi_1^\ell - \xi_3^\ell)^2 - 2(h_1^{\ell-1} - h_3^{\ell-1})(\xi_1^\ell - \xi_3^\ell) - (\xi_1^\ell - \xi_2^\ell)^2 + 2(h_1^{\ell-1} - h_2^{\ell-1})(\xi_1^\ell - \xi_2^\ell) \geq 0$$

아래와 같이 나누자.

$$\begin{aligned} A_1 &:= (\xi_1^\ell - \xi_3^\ell)^2 - (\xi_1^\ell - \xi_2^\ell)^2 \\ A_2 &:= -2(h_1^{\ell-1} - h_3^{\ell-1})(\xi_1^\ell - \xi_3^\ell) + 2(h_1^{\ell-1} - h_2^{\ell-1})(\xi_1^\ell - \xi_2^\ell) \end{aligned}$$

- 먼저 $\ell - 1$ 시점에서 눈이 갇힌 (blocked) 경우를 고려하자. 눈이 갇히고 노드 1에 왔다면 $A_1 = 0$ 이다. 따라서

$$A = A_2 = 2b(h_3^{\ell-1} - h_2^{\ell-1})$$

블락된 이후 노드2로 왔다면 $A_1 = -b^2$ 이고

$$A = -b^2 + A_2 = -b^2 + 2b(h_1^{\ell-1} - h_2^{\ell-1}) = 2b\left(h_2^{\ell-1} - h_1^{\ell-1} - \frac{b}{2}\right)$$

블락된 이후 노드3으로 왔다면 $A_1 = b^2$ 이고

$$A = b^2 + A_2 = b^2 + 2b(h_1^{\ell-1} - h_3^{\ell-1}) = 2b\left(h_1^{\ell-1} - h_3^{\ell-1} + \frac{b}{2}\right)$$

블락된 이후에 각 경우에 대하여 평균적으로 A 는

$$2b\left(h_3^{\ell-1} - h_2^{\ell-1} + h_2^{\ell-1} - h_1^{\ell-1} - \frac{b}{2} + h_1^{\ell-1} - h_3^{\ell-1} + \frac{b}{2}\right) = 0$$

이는 지형에 상관없이 성립한다. 따라서 블락된 경우는 따질 필요가 없다.

- ℓ 시점에서 눈이 쌓이는 경우는 아래의 경우가 있다.
- $(\xi_1^\ell, \xi_2^\ell, \xi_3^\ell) = (0, 0, 0) \implies A = 0 := a_0$
- $(\xi_1^\ell, \xi_2^\ell, \xi_3^\ell) = (\tilde{b}, 0, 0) \implies A = 2\tilde{b}(h_3^{\ell-1} - h_2^{\ell-1}) := a_1$
- $(\xi_1^\ell, \xi_2^\ell, \xi_3^\ell) = (0, \tilde{b}, 0) \implies A = 2\tilde{b}\left(h_2^{\ell-1} - h_1^{\ell-1} - \frac{\tilde{b}}{2}\right) := a_2$
- $(\xi_1^\ell, \xi_2^\ell, \xi_3^\ell) = (0, 0, \tilde{b}) \implies A = 2\tilde{b}\left(h_1^{\ell-1} - h_3^{\ell-1} + \frac{\tilde{b}}{2}\right) := a_3$

note: $a_1 + a_2 + a_3 = 0$ 임에 유의할것.

- case2-1 ~ case 3-4의 경우는 아래가 성립함이 자명함. (추후에 좀더 엄밀하게 서술할것임)

$$\Sigma_{13}^\ell - \Sigma_{12}^\ell \geq 0$$

case 1-1 ~ 1-4:

- cases 1-1의 경우 (7번노드) $A = 0$ (1번노드)

- (1) $A = 0$
- (2) $A = \frac{a_1+a_3}{2}$
- (3) block
- (4) $A = \frac{3a_3}{4}$
- 따라서 $\frac{5a_1+2a_3}{4}$

1-2:

- (7) $A = 0$
- (1) $A = 0$
- (2) $A = \frac{a_1+a_3}{2}$
- (3) $A = 0$

(4) $A = 0$

- 따라서 $\frac{2a_1+2a_3}{4}$.

1-3:

(7) $A = \frac{3a_1}{4}$

(1) block

(2) $A = \frac{a_1+a_3}{2}$

(3) block

(4) $A = \frac{3a_3}{4}$

- 따라서 $\frac{4a_1+4a_3}{4}$.

1-4:

(7) $A = \frac{3a_1}{4}$

(1) block

(2) $A = \frac{a_1+a_3}{2}$

(3) $A = 0$

(4) $A = 0$

- 따라서 $\frac{5a_1+2a_3}{4}$.

- 경우1을 종합하면 $\frac{16a_1+10a_3}{4}$

4-1:

(7) $A = 0$

(1) $A = \frac{a_2}{2}$

(2) block

(3) $A = a_2$

(4) $A = \frac{3a_3}{4}$

• 따라서 $\frac{6a_2+3a_3}{4}$

4-2:

(7) $A = 0$

(1) $\frac{a_2}{2}$

(2) block

(3) $\frac{a_2}{2}$

(4) $A = 0$

• 종합 $\frac{4a_2}{4}$

4-3:

(7) $A = \frac{3a_1}{4}$

(1) $A = a_2$

(2) block

(3) $A = a_2$

(4) $A = \frac{3a_3}{4}$

• 종합 $\frac{3a_1+8a_2+3a_3}{4}$

4-4:

(7) $A = \frac{3a_1}{4}$

(1) $A = a_2$

(2) block

(3) $A = \frac{a_2}{2}$

(4) $A = 0$

- 종합 $\frac{6a_2+3a_3}{4}$
- 경우4를 종합하면 $\frac{3a_1+18a_2+9a_3}{4} = \frac{16a_2+6a_3}{4}$
- 경우1과 경우4를 종합하면 $\frac{16a_1+10a_3}{4} + \frac{16a_2+6a_3}{4} = \frac{16a_1+16a_2+16a_3}{4} = 0$



Theorem:

- 예제2에서 링과 링이 아닌 그룹은 분리가능함.



Theorem:

- 변형된 예제1의 caseA의 경우 2개 그룹은 서로 분리가능함.



Theorem (틀린듯): Let $\mathcal{G} = (V, \mathbf{E}, \mathbf{W})$ be a weighted graph with $|V| = n$ and f be the graph function defined on \mathcal{G} . Assume that \mathcal{G} is a regular graph. Suppose that $f(v_1), \dots, f(v_n)$ is *i.i.d* random sample. Let $\mathcal{G}^\tau = (V, \mathbf{E}, \mathbf{W}^\tau)$ be the weighted graph induced by the heavy snow transformation of f $\mathcal{H}(f, \mathcal{G}; \tau)$. Then we have $\mathbf{W}^\tau \xrightarrow{p} \mathbf{W}$ element-wisely as $\tau \rightarrow \infty$.

Proof. Using the results in Appendix A.2, we obtain $W_{ij}^\tau \sim N(T_{ij}(F), V_{ij}(T, F)) /$ where $T_{ij}(F) := \int W_{ij}^\tau dF^\tau$. Note that $T_{ij}(F^\tau) \rightarrow 1$ as $\tau \rightarrow \infty$ for $i \neq j$ and $T_{ij}(F^\tau) = 0$ for $i = j$. Further, we get $V_{ij}(T, F^\tau) / n \rightarrow 0$ as $\tau \rightarrow \infty$ for all i, j . Thus $\mathbf{W}^\tau \xrightarrow{p} \mathbf{W}$ element-wisely as $\tau \rightarrow \infty$.

Appendix 2: Let $\mathcal{G} = (V, \mathbf{E}, \mathbf{W})$ be a weighted graph with $|V| = n$ and f be a graph signal defined on \mathcal{G} . Assume that \mathcal{G} is a regular graph. Suppose that $f(v_1), \dots, f(v_n)$ is *i.i.d* random sample. Let $\mathcal{H}(f, \mathcal{G}; \tau)$ be the heavy snow transformation of f . Since $f(v_i)$ is *i.i.d.* random variable, \mathbf{h}_i is *i.i.d.* random vector with $\mathbf{h}_1^\tau, \dots, \mathbf{h}_n^\tau \sim F^\tau$. Define a functional $T(F^\tau)$ as $T(F^\tau) := \int g(\mathbf{h}) dF^\tau$. Let F_n^τ be an empirical distribution function of $\mathbf{h}_1^\tau, \dots, \mathbf{h}_n^\tau$ defined as

$$F_n^\tau(m) := \frac{1}{n} \sum_{i=1}^n 1(\mathbf{h}_i^\tau \leq t).$$

From Glivenko-Cantelli Lemma, we obtain $F_n^\tau \rightarrow F^\tau$. Thus, for a sufficiently large n , we can say that F_n^τ is a neighborhood of F^τ . Hence, we have

$$\begin{aligned} T(F_n^\tau) &\approx T(F^\tau) + \int IF(\mathbf{h}^\tau, T, F^\tau) d(F_n^\tau - F^\tau) \\ &= T(F^\tau) + \int IF(\mathbf{h}^\tau, T, F^\tau) dF_n^\tau, \end{aligned}$$

where $IF(\mathbf{h}^\tau; T, F^\tau) = \lim_{t \downarrow 0} \frac{T((1-t)F^\tau + t\delta(\mathbf{h})) - T(F^\tau)}{t}$ is an influence function of T . Here, $\int IF(\mathbf{h}^\tau, T, F^\tau) dF^\tau = 0$ is used. Therefore, it follows that

$$\sqrt{n} \left(T(F_n^\tau) - T(F^\tau) \right) \rightarrow N(0, V(T, F^\tau)),$$

where $V(T, F^\tau) = \int IF(\mathbf{h}^\tau, T, F^\tau)^2 dF^\tau$.

Theorem: 고정된 n 에 대하여

(i) $\theta_n^\tau \rightarrow \infty$ as $\tau \rightarrow \infty$

(ii) $\max_{i,j} |f(v_i) - f(v_j)| = O(1)$

이라면 아래를 만족하는 π^* 가 항상 존재한다.

$$\|\boldsymbol{\pi} - \boldsymbol{\pi}^*\|_2^2 = o(1)$$

단 $\pi_i^\tau := \frac{d_i^\tau}{\sum_i^n d_i^\tau}$, $d_i^\tau = \sum_{j=1}^n W_{ij}^\tau$ and $W_{ij}^\tau = \begin{cases} \exp\left(-\frac{1}{2} \frac{\Sigma_{ij}^\tau}{(\theta_n^\tau)^2}\right) & i \neq j \\ 0 & i = j \end{cases}$

Proof. 모든 $v_i \in V$ 에 대하여 아래를 보이면 된다.

$$\pi_i^\tau - \pi_i^{\tau-1} = \frac{d_i^\tau}{d_1^\tau + \dots + d_n^\tau} - \frac{d_i^{\tau-1}}{d_1^{\tau-1} + \dots + d_n^{\tau-1}} = o(1)$$

따라서 아래를 보이면 된다.

$$\frac{d_i^\tau}{d_1^\tau + \dots + d_n^\tau} = \frac{d_i^{\tau-1}}{d_1^{\tau-1} + \dots + d_n^{\tau-1}} + o(1)$$

case1: : $d_1^\tau + \dots + d_n^\tau = d_1^{\tau-1} + \dots + d_n^{\tau-1}$ 이라고 하자.

- 아래를 보이기만 하면 된다.

$$d_i^\tau - d_i^{\tau-1} = o(1)$$

그런데

$$d_i^\tau = W_{i1}^\tau + W_{i2}^\tau + \dots + W_{in}^\tau = W_{i2}^\tau + \dots + W_{in}^\tau$$

이므로 아래를 보이면 된다.

$$(W_{i1}^\tau - W_{i1}^{\tau-1}) + \dots + (W_{in}^\tau - W_{in}^{\tau-1}) = o(1)$$

결국 모든 j 에 대하여 아래를 보이면 된다.

$$W_{ij}^\tau - W_{ij}^{\tau-1} = o(1)$$

따라서 아래를 보이면된다.

$$\frac{W_{ij}^\tau}{W_{ij}^{\tau-1}} - 1 = o(1)$$

note: 아래를 관찰하자.

$$W_{ij}^\tau = e^{-\frac{\Sigma_{ij}^\tau}{2(\theta_n^\tau)^2}} = e^{-\frac{1}{2}\left(\frac{h_i^0-h_j^0}{\theta_n^\tau}\right)^2} e^{-\frac{1}{2}\left(\frac{h_i^1-h_j^1}{\theta_n^\tau}\right)^2} \dots e^{-\frac{1}{2}\left(\frac{h_i^{\tau-1}-h_j^{\tau-1}}{\theta_n^\tau}\right)^2} e^{-\frac{1}{2}\left(\frac{h_i^\tau-h_j^\tau}{\theta_n^\tau}\right)^2}$$

$$W_{ij}^{\tau-1} = e^{-\frac{\Sigma_{ij}^{\tau-1}}{2(\theta_n^{\tau-1})^2}} = e^{-\frac{1}{2}\left(\frac{h_i^0-h_j^0}{\theta_n^{\tau-1}}\right)^2} e^{-\frac{1}{2}\left(\frac{h_i^1-h_j^1}{\theta_n^{\tau-1}}\right)^2} \dots e^{-\frac{1}{2}\left(\frac{h_i^{\tau-1}-h_j^{\tau-1}}{\theta_n^{\tau-1}}\right)^2}$$

- 따라서

$$\frac{W_{ij}^\tau}{W_{ij}^{\tau-1}} = A_1 \times \dots \times A_{\tau-1} \times A_\tau$$

이때

$$\begin{aligned}
A_0 &= \exp \left(-\frac{1}{2} \left(\frac{1}{(\theta_n^\tau)^2} - \frac{1}{(\theta_n^{\tau-1})^2} \right) (h_i^0 - h_j^0)^2 \right) \\
A_1 &= \exp \left(-\frac{1}{2} \left(\frac{1}{(\theta_n^\tau)^2} - \frac{1}{(\theta_n^{\tau-1})^2} \right) (h_i^1 - h_j^1)^2 \right) \\
&\dots \\
A_{\tau-1} &= \exp \left(-\frac{1}{2} \left(\frac{1}{(\theta_n^\tau)^2} - \frac{1}{(\theta_n^{\tau-1})^2} \right) (h_i^{\tau-1} - h_j^{\tau-1})^2 \right) \\
A_\tau &= \exp \left(-\frac{1}{2} \frac{1}{(\theta_n^\tau)^2} (h_i^\tau - h_j^\tau)^2 \right)
\end{aligned}$$

(1) 그런데

$$\frac{1}{(\theta_n^\tau)^2} - \frac{1}{(\theta_n^{\tau-1})^2} = o(1)$$

이다. 왜냐하면 $\left\{ \frac{1}{(\theta_n^\tau)^2} \right\}_{\tau=1}^\infty$ 이 수렴하는 수열이기 때문이다. (수렴하는 수열은 코시수열임)

(2) 또한 모든 τ 에 대하여

$$\max_{i,j} |h_i^\tau - h_j^\tau| = O(1)$$

이다. (한쪽에만 눈이 쏠릴수는 없음.)

(3) \exp 가 연속함수이므로 $A_1, \dots, A_{\tau-1}$ 는 모두 1로 수렴한다. 그리고 A_τ 역시 1로 수렴한다.

• 따라서

$$\frac{W_{ij}^\tau}{W_{ij}^{\tau-1}} = 1 + o(1)$$

case2: : 이제 $d_1^\tau + \dots + d_n^\tau \neq d_1^{\tau-1} + \dots + d_n^{\tau-1}$ 라고 하자. 아래를 정의하자.

$$\begin{aligned}
d^{\tau-1} &= d_1^{\tau-1} + \dots + d_n^{\tau-1} \\
d^\tau &= d_1^\tau + \dots + d_n^\tau \\
\tilde{d}^\tau &= \max(d^\tau, d^{\tau-1})
\end{aligned}$$

Clearly,

$$\tilde{d}^\tau = O(1)$$

따라서 case1 을 반복하면 증명이 된다.

lem: (1) $\mathcal{G} = (\mathcal{V}, \mathbf{E}, \mathbf{W})$ 를 모든 엣지가 연결된 레귤러 그래프라고 하자. 즉 $\mathbf{W} = \mathbf{J} - \mathbf{I}$. (2) $f_1, \dots, f_{100} \stackrel{iid}{\sim} N(\mu_1, 1)$. 그러면 아래가 성립한다.

$$\mathbf{W}^\tau \xrightarrow{p} \mathbf{J} - \mathbf{I}$$

lem: (1) $\mathcal{G} = (\mathcal{V}, \mathbf{E}, \mathbf{W})$ 를 모든 엣지가 연결된 레귤러 그래프라고 하자. 즉 $\mathbf{W} = \mathbf{J} - \mathbf{I}$. (2) $f_1, \dots, f_{50} \stackrel{iid}{\sim} N(\mu_1, 1)$ and $f_{51}, \dots, f_{100} \stackrel{iid}{\sim} N(\mu_2, 1)$. 그러면 아래가 성립한다.

$$\mathbf{W}^\tau \xrightarrow{p} \begin{bmatrix} \mathbf{J} - \mathbf{I} & \mathbf{0} \\ \mathbf{0} & \mathbf{J} - \mathbf{I} \end{bmatrix}$$



thm: 눈을 쌓을수록 노드정보를 상실한다. HST는 노드정보와 그래프도메인에서의 정보를 연속적으로 변화시키는 장치이다.

note: 단순히 노드에서의 거리와 그래프도메인의 거리를 가중평균한것과 무슨 차이일까?