

1 Measure Theory

- 여기서는 듀렛책 챕터 1.1 ~ 1.3 사이의 내용을 다룬다. 이 내용들은 probability spaces, distributions, random variable에 대한 내용인데 전반적으로 적분이전의 measure theory에 관한 내용이다. 개인적으로 책이 상당히 두서없이 정리되어 있다고 생각한다. 그래서 나도 두서없이 내맘대로 정리하였다.
- 확률변수 X 에 대한 정의를 생각하여 보자. 확률변수는 본질적으로 메저러블-맵핑이므로 메저러블-매핑의 정의에 대하여 알아보자. 어떠한 맵핑 X 가 메저러블-스페이스 (Ω, \mathcal{F}) 와 메저러블-스페이스 (S, \mathcal{S}) 를 이어주는 메저러블-맵핑이라는 의미는 1) X 가 Ω 에서 S 로 가는 함수이고 즉 $X : \Omega \rightarrow S$ 이고 2) X^{-1} 가

$$\forall B \in \mathcal{S} : X^{-1}(B) \in \mathcal{F}$$

를 만족한다는 의미이다.

- 확률변수 X 라는 것을 정의하기 위해서는 반드시 두 메저러블-스페이스가 필요하다. 확률변수 X 단독으로 정의될 수 없다. 이것은 비유하면 "남친"의 정의와 비슷하다. 남친은 혼자 될 수 있는 것이 아니다. 즉 남친은 단독으로 정의될 수 없고 "XXX의 남친"과 같은 식으로만 정의된다. 예를 들면

"저는 남친이에요"

라고 말하는것은 올바른 정의가 아니며

"저는 XXX의 남친이에요"

라고 말하는 것이 올바른 정의이다. 이처럼

" X 는 확률변수예요"

라고 말하는 것은 올바른 정의가 아니며 (하지만 유감스럽게도 대부분 이렇게 말하고, 그래서 확률변수가 무엇인지 헷갈려한다. 그리고 내가 매년 이러고 있다..)

" X 는 두 메저러블-스페이스 (Ω, \mathcal{F}) 와 (S, \mathcal{S}) 를 연결하는 확률변수예요"

라고 말하는것이 올바른 정의라는 것이다. 요런 느낌의 정의를 확률론에서는 많이 가지고 있다. 가령 예를들면 시그마필드 \mathcal{F} 는 홀로 정의될 수 없고 전체집합 Ω 가 존재해야지 정의된다. 그리고 임의의 메저러블셋 A 은 시그마필드 \mathcal{F} 가 있어야지 정의될 수 있다. 즉 아래와 같이 말한다.

" \mathcal{F} 는 Ω 에 대한 시그마필드예요"

혹은

"집합 A 는 시그마필드 \mathcal{F} 에 대해서 메저러블해요"

와 같은 식으로 말이다.

- 확률변수는 사실 메저러블-맵핑중에서 매우 특수한 경우이다. 왜냐하면 "이미지(=image)"에 해당하는 메저러블-스페이스 (S, \mathcal{S}) 가 $(\mathbb{R}, \mathcal{R})$ 로 고정되어있기 때문이다. 여기에서 \mathcal{R} 은 보렐클래스이다. 그러면 사실 확률변수 X 를 정의하는데 $\Omega, \mathcal{F}, S, \mathcal{S}$ 를 일일이 정의할 필요는 없어진다. $(S, \mathcal{S}) = (\mathbb{R}, \mathcal{R})$ 은 이미 정해졌고 Ω 는 \mathcal{F} 를 정의하면 사실 같이 정의된 셈이나 마찬가지다(\mathcal{F} 에서 가장 큰 원소가 Ω 일테니깐!). 종합하면 확률변수 X 를 정의할때는 \mathcal{F} 만 정의하면 된다. 따라서

" X 는 두 메저러블-스페이스 (Ω, \mathcal{F}) 와 (S, \mathcal{S}) 를 연결하는 확률변수예요"

라고 말하는것이 정확하지만

" X 는 \mathcal{F} 에서 정의된 확률변수예요"

라고 말해도 틀린말은 아니라는 것이다. 그리고 이렇게 말하는 것을 더 좋아하는 사람들이 많다(간단하니깐). 그리고 이것을 기호로는

$$X \in \mathcal{F}$$

라고 쓴다.

- 아마 나는 이 포스팅을 읽을때마다 보렐클래스가 무엇인지 다시 헷갈리기 시작할것이다(나 자신에 대한 끝없는 불신..). 그래서 보렐클래스에 대해서 다시 정의하고 넘어가겠다. 보렐클래스 \mathcal{R} 이란 \mathbb{R} 의 모든 오픈셋을 포함하는 시그마필드라는 것이다. 좀 더 엄밀하게 써보자. 집합 O 를 \mathbb{R} 에 속하는 임의의 오픈셋이라고 하자. 즉

$$O \subset \mathbb{R} \text{ and } O \text{ is open set}$$

이라고 하자. 이러한 집합 O 들을 모아놓은 클래스를 \mathcal{O} 를 정의하자. 즉

$$\mathcal{O} = \{O : O \subset \mathbb{R}, \text{ } O \text{ is open set}\}$$

이다. \mathcal{R} 은 \mathcal{O} 를 포함하는 가장 작은 시그마필드이다. 즉 (1) $\mathcal{O} \subset \mathcal{R}$ 이고 (2) " \mathcal{R} is σ -field." 이다. 이것을 기호로는 아래와 같이 쓴다.

$$\mathcal{R} = \sigma(\mathcal{O})$$

그리고 \mathcal{R} 을 \mathcal{O} 에 의해서 제너레이트된 시그마필드라고도하며 \mathcal{O} 가 \mathcal{R} 을 생성했다고 말하기도 한다.

- 보렐클래스는 우리가 상상할 수 있는 대부분의 "subset of \mathbb{R} "을 포함한다. 가령 예를들면 보렐클래스는 점집합, 인터벌, 레이와 같은 집합들을 포함하는데 이는 이러한 집합들이 (a, b) 의 카운터블 유니온꼴로 표현될 수 있다는 것을 알면 쉽게 이해할 수 있다. 이러한 집합을 \mathcal{R} -메저러블한 집합이라고 표현한다. 간단히 줄여서 보렐셋이라고 표현하기도 한다. 하지만 "subset of \mathbb{R} "임에도 불구하고 가끔 가다가 보렐클래스의 원소가 아닌 이상한 집합이 있을 수도 있다. 이런 집합을 보렐클래스의 원소가 아닌 집합 혹은 \mathcal{R} -메저러블하지 않은 집합 혹은 보렐셋이 아닌 집합이라고 한다. 대표적으로 비탈리집합이 있다.

- 보렐셋 즉 \mathcal{R} -메저러블한 집합은 \mathbb{R} 에서 "**길이를 잴 수 있는 집합**"이라고 이해해도 괜찮다. 가령 예를 들면 $[0, 1]$ 의 길이는 1이고 \emptyset 의 길이는 0이다. 또한 $\{0\}$ 와 같은 집합의 길이는 0, 유리수들의 집합의 길이는 0, 그리고 $[0, 1]$ 사이에 포함된 무리수들의 집합을 길이로 재면 1과 같은식으로 정의할 수 있다. 따라서 위에서 언급한 집합들은 모두 잴 수 있는 집합이며, \mathcal{R} -메저러블한 집합이다.

- 참고로 위와 같이 길이를 재는 함수를 **르벡메저**라고 한다. 르벡메저는 \mathcal{R} 에 속한 임의의 집합에 대하여서도 이러식으로 **모순없이** 길이를 정의할 수 있다. 여기에서 모순없이 길이를 잴 수 있다는 말이 의미하는 것은 (1) 공집합의 길이는 0이며 (2) \mathcal{R} 에 속하는 어떠한 집합의 길이도 양수이어야 하며 3) \mathcal{F} 에 속하는 두 집합이 서로소라면(즉 $[0, 1]$, $[3, 4]$ 와 같은 집합) 두 집합의 합집합의 길이는 각각의 길이의 합과 같아야 한다는 것이다(즉 $[0, 1] \cup [3, 4]$ 의 길이는 $[0, 1]$ 의 길이와 $[3, 4]$ 의 길이의 합과 같아야 한다는것임). 어떠한 클래스 \mathcal{F} 에서 이러한 위와 같은 조건을 만족하는 함수 μ 가 있다고 하면 이때 μ 는 \mathcal{F} 의 모든 원소들의 크기(혹은 길이)를 **모순없이** 정의할 수 있다. 이러한 함수 $\mu : \mathcal{F} \rightarrow [0, \infty]$ 를 \mathcal{F} 에서의 메저라고 한다. 참고로 **르벡메저** λ 는 아래와 같이 정의되는 함수이다.

$$\lambda((a, b)) = b - a$$

이러한 함수 λ 는 보렐클래스 \mathcal{R} 에 있는 모든집합에 대하여 **모순없이** 길이를 정의할 수 있다. 따라서 λ 는 \mathcal{R} 에 대한 메저이다.

- 다시 X 로 관심을 돌려보자. X 는 기본적으로 Ω 와 \mathbb{R} 을 연결하는 맵핑이다. 이것이 (Ω, \mathcal{F}) 와 $(\mathbb{R}, \mathcal{R})$ 을 연결하는 맵핑, 즉 메저러블 맵핑이 되려면 어떻게 되어야 할까? 해답은 매우 간단하다. Ω 의 원소들을 근원사건으로 해석하여 맵핑하지말고 \mathcal{F} 의 (공집합을 제외한) 가장 작은 원소들을 근원사건으로 해석하여 맵핑시키면 된다. 이제 이게 무슨말인지 찬찬히 살펴보자. 예를들어

$$\Omega = \{1, 2, 3, 4, 5, 6\}$$

이라고 하자. 즉 주사위를 던져서 나오는 눈들의 집합이 Ω 이다. Ω 의 원소를 기준으로 이해한 근원사건은 다음과 같다.

- 주사위를 던져서 눈이 1이 나올 경우
- ...
- 주사위를 던져서 눈이 6이 나올 경우

이제 Ω 에 대한 시그마필드를 아래와 같이 정의하자.

$$\mathcal{F} = \{\emptyset, \{1, 3, 5\}, \{2, 4, 6\}, \Omega\}.$$

즉 \mathcal{F} 의 원소는 (1) 공집합 (2) 전체집합 그리고 (3) 주사위를 던져서 짝수가 나오는 경우를 모은 집합 (4) 주사위를 던져서 홀수가 나오는 경우를 모은 집합이다. 이 경우 \mathcal{F} 의 (공집합을 제외한) 가장 작은 원소를 기준으로 이해한 근원사건은 다음과 같다.

- 주사위를 던져서 짝수가 나올 경우
- 주사위를 던져서 홀수가 나올 경우

X 가 단지 Ω 에서 \mathbb{R} 의 맵핑이 아니라 (Ω, \mathcal{F}) 에서 $(\mathbb{R}, \mathcal{R})$ 로 메저러블맵핑이 되려면 \mathcal{F} 의 (공집합을 제외한) 가장 작은 원소를 기준으로 맵핑을 해야한다. 즉

$$X(\{1\}) = 1$$

$$\dots$$

$$X(\{6\}) = 6$$

와 같이 맵핑을 하면 안되고

$$X(\{1\}) = X(\{3\}) = X(\{5\}) = 1$$

$$X(\{2\}) = X(\{4\}) = X(\{6\}) = 0$$

와 같은 식으로 맵핑을 해야한다는 것이다. 참고로 전자의 맵핑은

$$"X: \text{주사위를 던져서 나오는 눈의 수}"$$

와 같은 식으로 확률변수를 구성한 것이고 후자의 경우는

$$"X: \text{주사위를 던져 홀수면 1 짝수면 0}"$$

과 같은 방식으로 확률변수를 구성한 것이다. 전자의 근원사건은 주사위를 던져서 나온 눈의 수이며 후자의 근원사건은 주사위를 던져서 짝수가 나왔는지 홀수가 나왔는지다. 참고로 후자의 경우처럼 X 를 맵핑해야 X 가 \mathcal{F} 에서 정의된 랜덤변수 즉 $X \in \mathcal{F}$ 라고 할 수 있는 것이다.

- $X \in \mathcal{F}$ 가 되도록 X 를 정의하기 위해서는 위처럼 \mathcal{F} 가 근원사건을 이해하는 방식으로 맵핑 X 를 정의해도 되지만 \mathcal{F} 보다 작은 어떤 시그마필드 \mathcal{F}^* 의 가장 작은 원소를 기준으로 맵핑 X 를 정의해도 된다. 예를들면 위의 예제처럼

$$\mathcal{F} = \{\emptyset, \{1, 3, 5\}, \{2, 4, 6\}, \Omega\}.$$

라고 하고 우리는 $X \in \mathcal{F}$ 가 되도록 맵핑 X 를 잘 정의하고 싶다고 하자. X 를 위의 예제처럼 \mathcal{F} 의 최소원소를 기준으로 맵핑하 아래와 같다.

$$X(\{1\}) = X(\{3\}) = X(\{5\}) = 1$$

$$X(\{2\}) = X(\{4\}) = X(\{6\}) = 0$$

당연히 $X \in \mathcal{F}$ 은 성립한다. 그렇다면 \mathcal{F} 보다 작은 집합 \mathcal{F}^* , 예를들면

$$\mathcal{F}^* = \{\emptyset, \Omega\}$$

와 같은 시그마필드의 최소원소를 기준으로 X 를 맵핑해도 여전히 $X \in \mathcal{F}$ 가 성립할까? 그러하다. 예컨데 아래와 같은식으로 X 를 맵핑해도된다.

$$X(\{1\}) = X(\{2\}) = X(\{3\}) = X(\{4\}) = X(\{5\}) = X(\{6\}) = 1.$$

이렇게 정의하여도 $X \in \mathcal{F}$ 가 성립한다. 단지 이러한 경우 \mathcal{F} 는 X 를 정의하기 위해서 필요한 최소한의(=가장작은) 시그마필드는 아니게 된다. 이 경우 X 를 정의하는데 필요한 최소한의 시그마필드는 \mathcal{F}^* 가 된다. 이처럼 맵핑 X 를 \mathcal{F} 메저러블하도록 만드는데 필요한 최소한의 시그마필드를 기호로 $\sigma(X)$ 라고 한다. 그리고 이 예제에서는 $\sigma(X) = \mathcal{F}^*$ 가 된다.

- 이제 \mathcal{F} 에서 정의된 어떠한 확률변수 X 가 \mathcal{F} 의 모든 사건들을 잘 연결하는 어떠한 맵핑이라는건 알겠다. 그런데 확률변수 X 가 어떤 **랜덤**한 출력을 주는 함수라는 느낌은 없다. 왜냐하면 말그대로 확률변수 X 는 두 메저러블 스페이스 $(\Omega, \mathcal{F}), (\mathbb{R}, \mathcal{R})$ 을 잘 연결하는 어떠한 맵핑일 뿐이기 때문이다. 즉 X 는 단순히 함수(혹은 맵핑)이기 때문에 $\omega \in \Omega$ 가 고정되면 $X(\omega)$ 의 값도 고정된다. 따라서 X 가 어떤 **랜덤**한 출력을 가지도록 하기 위해서는 ω 를 랜덤하게 선택하는 수밖에 없다. 이렇게 ω 를 랜덤하게 선택할 수 있게 만들어주는 장치가 바로 확률척도 $P : \mathcal{F} \rightarrow \mathbb{R}$ 이다. $P(\{\omega\})$ 는 Ω 에서 $\{\omega\}$ 가 선택될 확률을 의미한다. 따라서 P 는 ω 를 **랜덤**하게 선택할수 있게 해주고 그 결과 $X(\omega)$ 의 출력 역시 **랜덤**하게 나올 수 있도록 해준다. 따라서 우리가 일반적으로 생각하는 확률변수 X 를 정의하기 위해서는 $(\Omega, \mathcal{F}), (\mathbb{R}, \mathcal{R})$ 과 더불어서 P 가 추가적으로 필요하다. 즉 확률변수 X 를 정의하기 위해서는 $(\Omega, \mathcal{F}, P), (\mathbb{R}, \mathcal{R})$ 이 필요하다. 여기에서 (Ω, \mathcal{F}, P) 를 묶어서 확률공간이라고 한다.

• 엄밀하게 말하면 X 를 정의하기 위해서는 (Ω, \mathcal{F}, P) , $(\mathbb{R}, \mathcal{R})$ 가 모두 필요하지만 앞에서 언급하였듯이 \mathcal{F} 를 알면 Ω 를 아는 셈이고 (\mathcal{F} 에서 켈 큰 집합이 Ω 임) $(\mathbb{R}, \mathcal{R})$ 는 이미 정해진 것이므로 X 를 정의하는데 최소한으로 필요한 정보는 \mathcal{F} 와 P 이다. 그런데 이 사실은 $X \in \mathcal{F}$ 라는 기호를 이상하게 느껴지게 만들 수 있다. 즉 " X 를 **well-define** 하는데 \mathcal{F} 만 필요하다고 하면 된다고 했는데 사실 그게 아니고 P 도 필요한것 아니야?" 라고 생각할 수 있다. 하지만 P 는 사실 X 가 가지는 **랜덤성**을 주기 위한 장치이고 **따라서 P 를 잘 못 정의한다고 하여서 X 가 랜덤변수가 아니게 되는 경우는 없다**(P 가 probability measure가 되도록만 정의하면 됨)는 사실을 유의하면 X 를 **well-define**하기 위해서는 P 가 필요하지 않음을 알 수 있다. 즉 아래의 기호는 여전히 유용하다.

$$X \in \mathcal{F}$$

• 그럼 P 가 가지는 역할은 무엇일까? P 는 X 는 가지는 분포를 결정하여 준다. 따라서 P 는 맵핑 X 가 확률변수인지 아닌지를 결정하지는 않지만 (이것은 \mathcal{F} 가 결정함) X 가 **어떠한** 확률변수인지는 결정한다. 즉 P 가 정의되면 부수적으로 X 가 가지는 여러가지 성질들을 추가적으로 **assume** 할 수 있다. 예를들어 P 는 확률변수의 모멘트가 유한한지 그렇지 않은지를 결정할 수 있으며 확률변수들이 독립인지 아닌지도 결정할 수 있다. (예컨데 $P := P_1 \times P_2$ 를 확률벡터 (X_1, X_2) 의 확률측도라고 하자. 여기에서 P_1, P_2 는 각각 X_1, X_2 의 probability measure이다. 이때 P 를 알고있다면 두 확률변수 X_1, X_2 가 독립인지 독립이 아닌지도 알 수 있다.)

• 확률척도 P 는 X 의 분포에 대한 정보를 담고 있지만 P 의 정의역은 \mathcal{F} 이다. P 의 정의역이 보렐셋 \mathcal{R} 이 아니기 때문에 종종 P 를 쓰기 불편할 때가 있다. 그래서 P 와 동등한 역할을 하는 또 다른 함수 $\mu^\star : \mathcal{R} \rightarrow [0, 1]$ 를 아래와 같이 만든다.

$$\mu^\star := P \circ X^{-1}.$$

이때 $\tilde{\mu}$ 를 확률변수 X 의 **distribution**이라고 정의한다. 이렇게 정의하면 임의의 집합 $B \in \mathcal{R}$ 에 대하여 아래식이 성립한다.

$$\mu^\star(B) = P(\{\omega : X(\omega) \in B\}) = P(A)$$

여기에서 $A := X^{-1}(B) := \{\omega : X(\omega) \in B\}$ 로 정의한다. 참고로 이때 μ^\star 는 확률측도가 된다(증명은 알아서 하든가 아니면 그냥 믿든가). 따라서 $(\mathbb{R}, \mathcal{R}, \mu^\star)$ 는 확률공간이 된다. 여기에서 μ^\star 가 X 에 의해서 정의되므로 확률공간 $(\mathbb{R}, \mathcal{R}, \mu^\star)$

역시 X 에 의해서 정의되는데 이러한 이유로 **확률공간** $(\mathbb{R}, \mathcal{R}, \mu^\star)$ 를 X 에 의해서 유도된 **확률공간**이라고 표현하기도 한다.

- 참고로 보통 교재에서는 μ^\star 대신에 간략하게 μ 를 쓴다. 나는 일반적인 메저 μ 와 확률변수 $X \in \mathcal{F}$ 의 distribution 으로서의 (probability) measure 를 구분하기 위해서 \star 를 붙였다.
- 확률변수 X 에 대한 **distribution** μ^\star 까지 잘 정의하였다면 확률변수 X 에 대한 **distribution function**을 정의할 수 있다. 확률변수 X 의 **distribution function** $F : \mathbb{R} \rightarrow [0, 1]$ 는 아래와 같이 정의한다.

$$F(x) = \mu^\star((-\infty, x]) = P(\{\omega : X(\omega) \leq x\})$$

$F(x)$ 는 X 의 **cdf**라고 표현하기도 한다. 참고로 $F(x)$ 는 (1) $F(-\infty) = 0, F(\infty) = 1$ 을 만족하고 (2) 비감소이며 (3) 오른쪽 연속인 함수가 된다. 그리고 임의의 함수 $F(x)$ 가 위의 3가지 조건을 만족하면 $F(x)$ 는 어떠한 확률변수 X 의 **distribution function**이 된다.

- 여기에서 어떠한 확률변수 X 인지 구체적으로 알아보도록 하자. 결론적으로

$$X(\omega) := \sup \{y : F(y) < \omega\}$$

와 같이 하면 이 확률변수는 $F(x)$ 를 **distribution function**으로 가지는 하나의 확률변수가 된다.

- 만약에 $F(x)$ 가 x 에 대하여 미분가능하다면

$$f(x) = \frac{d}{dx}F(x)$$

를 만족하는 $f(x)$ 를 정의할수 있는데 이때 $f(x)$ 를 X 의 **probability density function**이라고 한다. 그럼 언제 $f(x)$ 가 존재할까? **라돈-니코딤 정리**는 X 의 **distribution**, $\tilde{\mu} : P \circ X^{-1}$ 가 르벡메저 λ 에 대하여 **absolutely continuous**하다면 X 의 pdf가 존재함을 시사한다.

- 좀 더 자세히 설명해보자. 내가 알고있기로는 결국 모든 $x \in \mathbb{R}$ 에 대하여

$$\int_{-\infty}^x f(\tau)d\tau = F(x)$$

가 만족하는 $f(x)$ 가 존재함을 보이면 된다. 참고로 위와 같이 고등학교에서 배운 것같은 기호로 정의된 적분은 **리만적분**이라고 보아도 무방하다. 참고로

$$\lambda\Big(\{x : f(x) \text{ is discontinuous on } x\}\Big) = 0$$

아래가 성립하면 $f(x)$ 는 리만적분가능에서 **르벡적분가능**으로 바뀌며 따라서

$$\int_{-\infty}^x f(\tau)d\tau = \int_{(-\infty,x]} f d\lambda$$

이 된다(김김계 해석개론, p.313, 정리 10.3.4). 여기에서 λ 는 르벡메저이다. 따라서 모든 $x \in \mathbb{R}$ 에 대하여 $\int_{-\infty}^x f(\tau)d\tau = F(x)$ 가 성립하는 f 가 존재함을 보이기 위해서는 모든 $B \in \mathcal{R}$ 에 대하여 아래식이 성립하게 하는 함수 f 가 존재함을 보이는 것과 같다.

$$\int_B f d\lambda = \mu^\star(B)$$

그런데 $\mu^\star \ll \lambda$ 이기만 하면 위의 식을 만족하는 메저 f 가 반드시 존재함이 **라돈-니코딤** 정리에 의하여 알려져 있다. 여기에서 $\mu^\star \ll \lambda$ 는 메저 μ^\star 가 메저 λ 에 대하여 **absolutely continuous**하다는 의미이다(제발 매우작다라고 해석하지 말자). 참고로 원래 **라돈-니코딤**정리를 쓰려면 μ^\star, λ 가 σ -finite 메저라는 조건이 추가적으로 필요한데 이 경우에는 μ^\star 는 확률측도이고 λ 는 르벡측도이므로 이 조건이 그냥 만족된다. 따라서 증명이 된다.

● 이제 $B := (-\infty, x] \in \mathcal{R}$ 와 $A := X^{-1}(B) \in \mathcal{F}$ 에 대하여 아래와 같은 기묘한 표현들을 파악하여 보자.

$$\begin{aligned} \int_A dP &= P(A) = P(X \in B) = \int_{X^{-1}(B)} dP = P(X^{-1}(B)) \\ &= \mu^\star(B) = \int_B d\mu^\star = \int_B \mu^\star(dx) = P(X \leq x) = \int_{-\infty}^x f(\tau)d\tau \\ &= \int_B f d\lambda = \int_B f(x)\lambda(dx) = \int_{-\infty}^x dF(\tau) = F(x) - F(-\infty) = F(x) \end{aligned}$$

참고로 여기에서 B 를 일반적인 보렐셋대신 ray를 사용하였는데, 이렇게 쓸 수 있는 이유는 임의의 보렐셋이 $(-\infty, x]$ 들의 **countable union**으로 쉽게 확장가능하기때문이다. (김김계 해석개론, p295, 명제 10.1.1) 예를들어서 $(1, 3] = (-\infty, 3] - (-\infty, 1]$ 와 같은 식으로 말이다. 아무튼 이걸 활용하면 임의의

보렐셋에 대한 적분도 표현가능하지만 그 표현법이 지저분하므로 B 를 ray로 단순화 시켰다. 참고로 아래와 같은 표현들도 자주 사용된다.

$$\begin{aligned} \int_A X dP &= \int_A X(\omega) P(d\omega) \int_{-\infty}^x \tau f(\tau) d\tau \\ &= \int_B x f(x) \lambda(dx) = \int_{-\infty}^x \tau dF(\tau) = \int_B x d\mu^\star = \int_B x \mu^\star(dx) \end{aligned}$$

참고로 위에서 $\int_{-\infty}^x \tau f(\tau) d\tau = \int_{-\infty}^x \tau dF(\tau)$ 는 스틸체스 적분의 성질 (김김계 해석개론, p.151, 정리 5.5.3)에 의해서 성립한다.

2 Integration

- 여기에서는 듀렛책 챕터 1.4 ~ 1.7의 내용을 다룬다.
- $f : \Omega \rightarrow \mathbb{R}$ 가 두 가측공간 (Ω, \mathcal{F}) 와 $(\mathbb{R}, \mathcal{R})$ 를 이어주는 매저러블-맵핑이라고 하자. 그리고 $\mu : \mathcal{F} \rightarrow \mathbb{R}$ 은 \mathcal{F} 에서의 메저라고 하자. 여기에서 특별히 μ 는 σ -finite measure라고 정의한다. 당분간은 $f = X$ 이고 $\mu = P$ 라고 생각해도 무방하다. (좀 더 발전하면 $f = f(X)$ 라고 두기도 한다. 어차피 $f(X)$ 즉 function of X 는 또 다른 확률변수로 볼 수 있으므로 같은 논의이다.) 이 챕터에서 우리의 관심은 (1) 매저러블-맵핑 f 를 메저 μ 로 적분한것 즉

$$\int f d\mu$$

를 잘 정의하고 (2) 적분관련 성질들을 자유자재로 계산할 수 있는 적당한 조건을 알아보는 것이다. 여기에서 적분관련 성질들은 예를들어

$$\int a f d\mu = a \int f d\mu$$

$$\int f + g d\mu = \int f d\mu + \int g d\mu$$

와 같은 것들을 의미한다.

- $\int f d\mu$ 를 정의하기 위해 필요한 기본가정을 살펴보자. 여기에서 $\mu := P$ 임을 유의하면서 읽자. (절대로 $\mu = \mu^\star$ 가 아님)

(1) $f : (\Omega, \mathcal{F}) \rightarrow (\mathbb{R}, \mathcal{R})$ 이어야 한다. 즉 f 가 메저러블 맵핑 이어야 한다. 왜냐하면 적분 $\int f d\mu$ 를 수행하기 위해서는 임의의 $B \in \mathcal{R}$ 에 대한 f 의 inverse image,

$$A := \{\omega : f \in B\}$$

를 구하고 그 A 에 대한 메저 $\mu(A)$ 를 계산해야 하는데, 이 $\mu(A)$ 가 정의되기 위해서는 $A \in \mathcal{F}$ 이어야 하기 때문이다.

(2) μ 가 σ -finite measure 이어야 한다. 왜냐하면 이 조건이 있어야 임의의 $A \in \mathcal{F}$ 에 대하여서도 $\mu(A) < \infty$ 가 성립하게 되어서 $d\mu$ 부분을 상당히 안정적으로 정의할 수 있다.

(3) f 와 μ 가 같은 시그마필드 \mathcal{F} 를 공유하고 있어야 한다.

(4) 마지막으로 μ 와 f 는 항상 치역 \mathbb{R} 을 가져야 한다. μ 는 당연히 정의상 치역을 \mathbb{R} 을 가질수 밖에 없으므로 f 의 치역이 항상 \mathbb{R} 이어야 한다는 조건으로 이해할 수 있다. 즉 f 는 치역으로 \mathbb{R}^n 도 가질 수 없다. 따라서 랜덤벡터와 같이 f 의 치역이 \mathbb{R}^n 인 경우는 바로 적분안된다. (μ 의 치역은 \mathbb{R} 가 되어서 임의의 $A \in \mathcal{F}$ 에 대하여 $f(A)\mu(A)$ 를 정의할 수 없다.)

● 왜 적분을 measure theory를 이용하여 정의할까? 고등학교때 정의하던대로 하면 안되나? 다 이유가 있어서 이렇게 정의하는 것이다. measure theory 를 이용하여 적분을 정의하면 고등학교때 배운 논리로 정의하기 애매하 적분들을 매우 깔끔하게 정의할 수 있다는 장점이 있다. 가령 예를들면 모든 유리수에서 1의 값을 가지고 나머지는 0을 가지는 함수 f 를 생각하여 보자. 즉 f 는 아래와 같다.

$$f(x) = \begin{cases} 1 & x \in \mathbb{Q} \\ 0 & x \notin \mathbb{Q} \end{cases}$$

이 함수 f 에 대한 적분은 고등학교때 배운 구분구적법 혹은 리만적분과 같은 방식으로는 정의할 수 없다(얼핏 생각하면 리만적분으로는 가능할것 같은데 불가능하다고 한다 f 를 리만적분하면 0과 1사이의 임의의 값이 랜덤으로 정의된다고 한다). 하지만 measure theory를 이용하면 이 적분값은 0으로 깔끔하게 정의된다. 즉

$$\int f d\lambda = 0$$

으로 깔끔하게 정의된다. 여기에서 λ 는 르벡측도이며 이러한 적분을 **르벡적분**이라고 한다. 기본적으로 구분구적법이나 리만적분은 f 가 연속이거나 부분적으로 연속이어야 할 것 같은 느낌인데 measure theory를 이용한 르벡적분은 f 가 매저러블 맵핑이기만 하면 되므로 좀 더 적분을 정의할 수 있는 함수의 선택폭이 넓다. 일단 \mathcal{R} 자체가 거의 대부분의 "subset of \mathbb{R} "을 커버하고 있기 때문에 \mathcal{R} -매저러블하지 않는 함수 $f : \mathbb{R} \rightarrow \mathbb{R}$ 는 별로없다고 보는 편이 좋다. 즉 르벡적분 불가능한 함수 $f : \mathbb{R} \rightarrow \mathbb{R}$ 는 별로없다고 보는것이 맞다.

● 이제 매저러블-맵핑 f 의 적분을 **모순없이** 정의하는 방법을 살펴보자. 적분은 기본적으로 넓이를 구하는 개념이므로 $f : \Omega \rightarrow \mathbb{R}$ 가 **simple function**일때 $\mu : \mathcal{F} \rightarrow \mathbb{R}$ 에 대한 적분은 사각형넓이의 유한합으로 매우 명확히 정의할 수 있다. 이것에 대한 내용이 듀렛책에 설명되어 있지만 당연한 소리라서 생략하겠다.

● 여기까지는 당연한거라서 우리의 관심은 " f 가 simple function이 아닐 경우에도 μ 에 대한 적분을 모순없이 잘 정의할 수 있을까?"가 된다. 결론적으로 **아래의 3가지 경우**에서는 적분값 $\int f d\mu$ 가 (마치 simple function 인것마냥) 모순없이 잘 정의되며 $\int a f d\mu = a \int f d\mu, \int f + g d\mu = \int f d\mu + \int g d\mu$ 따위의 성질들도 모순없이 잘 성립한다.

- (1) f 가 μ 에 대하여 *거의(=almost) bounded function*인 경우
- (2) f 가 μ 에 대하여 *거의(=almost) non-negative function*인 경우
- (3) f 가 μ 에 대하여 *integrable*인 경우, 즉 $\int |f| d\mu < \infty$ 인 경우

● 먼저 (1) f 가 bounded function인 경우를 살펴보자. f 를 두 simple function ϕ, ψ 사이에 끼워넣고, 즉 $\phi \leq f \leq \psi$ 와 같이 만든 다음 $\int f d\mu$ 를 아래와 같이 정의하면 f 가 simple function 일때 마냥 μ 에 대한 적분값을 잘 정의할 수 있다.

$$\sup_{\phi \leq f} \int \phi d\mu = \int f d\mu = \inf_{\psi \geq f} \int \psi d\mu.$$

참고로 위의 정의가 말이 되려면 즉 모순이 되지 않으려면

$$\sup_{\phi \leq f} \int \phi d\mu = \inf_{\psi \geq f} \int \psi d\mu$$

가 성립해야 하는데 이것이 성립하는 것은 듀렛책에 증명이 되어있다.

- 위의 결과를 이용하면 (2) f 가 non-negative function인 경우에도 μ 에 대한 적분을 쉽게 정의할 수 있다. 먼저 h 를 $0 \leq h \leq f$ 를 만족하는 bounded function 이라고 하자. $\int f d\mu$ 는 아래와 같이 $\int h d\mu$ 의 sup으로 정의할 수 있다.

$$\int f d\mu = \sup_{0 \leq h \leq f} \int h d\mu$$

- 이제 (3)의 경우를 살펴보자. 일반적인 f 는 아래와 같이 표현가능하다.

$$f = f^+ - f^-$$

따라서 $\int f d\mu$ 는 아래와 같이 정의할 수 있다.

$$\int f d\mu = \int f^+ d\mu - \int f^- d\mu$$

단지 위의 식이 모순없이 정의되려면 $\int f^+ d\mu$ 와 $\int f^- d\mu$ 이 모두 무한대이면 안되는데 이런 경우는 $\int |f| d\mu < \infty$ 라는 조건에 의해서 방지된다.

- 참고로 $\int |f| d\mu < \infty$ 를 만족하는 f 를 우리는 **integrable하다**고 하는데 이 표현이 좀 사람 헷갈리게 만든다. 즉

$$\begin{aligned} f \text{ is integrable wrt to } \mu \\ \iff \int f d\mu \text{ has finite value} \end{aligned}$$

이다. 그래서 나는 이 표현대신에 **유한적분값을 가진다**라고 표현하겠다.

note: 즉 교재에서 인테그러블 하다는 것은 말그대로 유한 적분값을 가진다는 말이지 적분을 모순없이 정의할 수 있다는 의미는 아니다. 아래를 참고하라.

- 르벡적분이 불가능한 경우 (= 적분이 well define 되지 않음).
- 르벡적분이 가능한 경우 (= 적분이 well define 됨).
 - (i) f 가 μ 에 대하여 integrable한 경우. 즉 $\int |f| d\mu < \infty$ 인 경우.
 - (ii) f 가 non-negative, a.e., wrt μ 인 경우. (**이 경우 $\int |f| d\mu = \infty$ 가능**)
 - (iii) f 가 bounded, a.e., wrt μ 인 경우.

3 Independence

Definition: 독립의 정의는 아래와 같다.

- Two events A and B are indep $\stackrel{def}{\iff} P(A \cap B) = P(A)P(B)$.
- Two random variables X and Y are indep $\stackrel{def}{\iff}$ for all $C, D \in \mathcal{R} : P(X \in C, Y \in D) = P(X \in C)P(Y \in D)$.
- Two σ -fields \mathcal{F} and \mathcal{G} are indep $\stackrel{def}{\iff}$ for all $A \in \mathcal{F}$ and $B \in \mathcal{G}$ the events A and B are indep.

아래예제에서 확인할 수 있듯이 2번째 정의는 3번째 정의의 스페셜케이스이다. ¹

Ex 2.1.1.: (i) X and Y 가 독립이면 $\sigma(X)$ and $\sigma(Y)$ 도 독립임을 보여라. (ii) 역으로 \mathcal{F} and \mathcal{G} 가 독립이고 $X \in \mathcal{F}$ and $Y \in \mathcal{G}$ 이면 X and Y 가 독립임을 보여라.

Ex 2.1.2.: (i) A and B 가 독립이면 A^c and B 도 독립이고 A^c and B^c 도 독립이고 A^c and B^c 도 독립임을 보여라. (ii) 아래를 보여라.

$$A \text{ and } B \text{ are indep} \iff 1_A \text{ and } 1_B \text{ are indep.}$$

- 확률변수의 독립
- 시그마필드의 독립

3.1 Sufficient conditions for Independence

Ex 2.1.18.: 코인을 무한히 던진다고 가정하자. $\Omega = (0, 1)$ 이고 \mathcal{F} 를 $(0, 1)$ 의 all open interval로 생성한 시그마필드라고 하자. (즉 보렐셋츠.) P 를 르벡메저라고 하자. 확률변수 $Y_n(\omega)$ 를 아래와 같이 정의하자.

$$Y_n(\omega) = \begin{cases} 1 & [2^n \omega] \text{ is odd.} \\ 0 & [2^n \omega] \text{ is even.} \end{cases}$$

그러면 Y_1, Y_2, \dots 는 서로 독립이고 $P(Y_k = 0) = P(Y_k = 1) = 1/2$ 이다.

¹As the next exercise shows, the second definition is a special case of the third.

4 WLLN

- WLLN 과 SLLN 은 근본적으로 어떠한 확률변수의 합 S_n 을 적당한 오더 b_n 으로 나누었을때 그 값이 하나의 값으로 p -수렴하는지를 따지는것이다. 즉

$$S_n/b_n \xrightarrow{p} ??$$

혹은

$$S_n/b_n \xrightarrow{as} ??$$

에 대하여 관심이 있다. 가장 이상적으로는 ?? 의 값이 $E(S_n/b_n)$ 이 되는 것인데 이러한 경우를 LLN이 성립한다고 한다. 구체적으로는 p -수렴이 성립하는 경우를 WLLN 이라고 하고 as -수렴이 성립하는 경우를 SLLN 이라고 한다.

- 주의할점은 우리가 항상 $S_n = X_1 + \dots + X_n$ 이며 $b_n = n$ 인 형태만 관심있는것은 아니라는 것이다. 가령 아래와 같은 것들의 수렴에 관심이 있을 수도 있다.

$$X_1, \frac{X_1 + 2X_2 + X_3}{1 + 2 + 1}, \frac{X_1 + 2X_2 + 3X_3 + 2X_4 + X_5}{1 + 2 + 3 + 2 + 1}, \dots$$

즉 일명 가중평균에 대한 관심이 있을수 있다. 특히 위와 같이 커널과 같은 방식으로 가중치를 줄 경우 수렴성에 대하여 관심을 많이 가진다. 이러한 가중평균을 잘 표현하는 방법중 하나는 바로 삼각수열 $X_{n,1}, \dots, X_{n,n}$ 을 활용하는 경우이다. 여기에서 $X_{n,1}$ 은 **weight $\times X_1$ 로 해석할 수 있다.** 따라서 통상적으로 S_n 은 아래와 같이 정의하는 것이 맞다.

$$S_n = X_{n,1} + X_{n,2} + \dots + X_{n,n}$$

- 앞에서 말한것처럼 WLLN 은 아래에 관심이 있다.

$$S_n/b_n \xrightarrow{p} ??$$

여기에서 ?? 의 값은 (case1) 하나의 실수값으로 수렴하지 않을 경우 (case2) 하나의 실수값으로 수렴은 하지만 그 실수값이 $E(S_n/b_n)$ 은 아닌 경우 (case3) 하나의 실수값으로 수렴하고 그 실수값이 $E(S_n/b_n)$ 인 경우로 나눌 수 있다.

- (case3)이 우리가 원하는 WLLN이다.

- (case1)가 가능하다는것 즉

$$\frac{S_n}{b_n} = \frac{X_{n,1} + \cdots + X_{n,n}}{b_n} \xrightarrow{p} \infty$$

와 같은 경우가 가능하다는것을 이해하는것은 매우 쉽다.

$$X_{n,1} = \text{weight} \times X_1$$

이라고 해석할 수 있는데 weight를 악의적으로 주면 (weight들의 총합이 b_n 보다 훨씬 크게) S_n/b_n 을 쉽게 발산시킬 수 있다.

- (case2)가 가능함을 이해하는것은 쉽지않다.
- WLLN에서 전제되는 중요한 조건들을 요약하면 아래와 같다.

- (1) 독립 혹은 무상관 조건
- (2) 동일한 분포에 대한 조건 (분산만 동일한지, 평균과 분산 모두 같은지, 동일한 분포를 가지는지 등)
- (3) 모멘트에 대한 조건 (평균이 존재하는지, 분산이 존재하는지 등)

Lemma 2.2.2: (3) 아래를 만족하는 적당한 r 을 선택할 수 있다고 하자.

$$E \left| \frac{X_{n,1} + \cdots + X_{n,n}}{b_n} - \frac{\mu_{n,1} + \cdots + \mu_{n,n}}{b_n} \right|^r \xrightarrow{p} 0$$

그러면 아래와 같은 WLLN이 성립함을 보일 수 있다.

$$\frac{X_{n,1} + \cdots + X_{n,n}}{b_n} \xrightarrow{p} \frac{\mu_{n,1} + \cdots + \mu_{n,n}}{b_n}.$$

Theorem 2.2.3.: (1) X_1, X_2, \dots 이 *uncorrelated random variables*이다. (2) X_1, X_2, \dots 의 평균은 모두 같은 값을 가지지만 분산이 같은 값을 가질필요는 없다. (3) X_1, X_2, \dots 의 분산을 유한한 값 C 로 바운드시킬 수 있다. (1)-(3)의 가정하에 아래와 같은 WLLN이 성립한다.

$$\frac{X_1 + \cdots + X_n}{n} \xrightarrow{p} \mu.$$

note: 참고로 이 조건하에서는 L_2 -convergence도 가능하다.

Theorem 2.2.4.: (3) $X_{n,1}, \dots, X_{n,n}$ 의 총합의 분산 즉 $V(X_{n,1} + \dots + X_{n,n})$ 보다 빠르게 발산하는 어떠한 b_n^2 을 잡을 수만 있다면, 즉

$$\frac{V(X_{n,1} + \dots + X_{n,n})}{b_n^2} \rightarrow 0$$

를 만족하는 b_n 을 잡을 수 있다면 아래와 같은 WLLN이 성립한다.

$$\frac{X_{n,1} + \dots + X_{n,n}}{b_n} \xrightarrow{p} \frac{\mu_{n,1} + \dots + \mu_{n,n}}{b_n}.$$

note: 조건 $\frac{V(X_{n,1} + \dots + X_{n,n})}{b_n^2} \rightarrow 0$ 는 결국

$$V(X_{n,1} + \dots + X_{n,n}) = o(b_n^2)$$

이라는 의미이다.

Theorem 2.2.6.: (1) $X_{n,1}, \dots, X_{n,k}$ 가 서로 독립이다. (3) $X_{n,1}, \dots, X_{n,k}$ 이 아래의 모멘트 조건들을 동시에 만족한다.

$$(\star) \quad \sum_{k=1}^n \int \mathbf{1}_{|X_{n,k}| > b_n} dP_k = o(1)$$

$$(\star\star) \quad \sum_{k=1}^n \int \frac{1}{b_n^2} X_{n,k}^2 \mathbf{1}_{|X_{n,k}| \leq b_n} dP_k = o(1)$$

이때 b_n 은 양수이고 무한대로 발산하는 수열이다. (1)-(3)의 가정하에 아래가 성립한다.

$$\frac{X_{n,1} + \dots + X_{n,n}}{b_n} \xrightarrow{p} \frac{\tilde{\mu}_{n,1}^{b_n} + \dots + \tilde{\mu}_{n,n}^{b_n}}{b_n}$$

여기에서 $\tilde{\mu}_{n,k}^{b_n} := E(X_{n,k} \mathbf{1}_{|X_{n,k}| \leq b_n}) = \int X_{n,k} \mathbf{1}_{|X_{n,k}| \leq b_n} dP_k$ 이다.

note: 위의 조건 $(\star), (\star\star)$ 는 Chung의 교재스타일로 정리한것이다. Durrett의 노테이션은 아래와 같다.

$$(\star) \quad \sum_{k=1}^n P(|X_{n,k}| > b_n) \rightarrow 0$$

$$(\star\star) \quad b_n^{-2} \sum_{k=1}^n E(X_{n,k}^2 \mathbf{1}_{|X_{n,k}| \leq b_n}) \rightarrow 0$$

위에서 엄밀하게 말하면 동일한 P 로 쓸수 없고 P_k 로 써야한다. E 역시 마찬가지로이다. 하지만 간결함을 위해서 (그리고 엄밀함을 희생했다) 듀렛책은 이렇게 표현한것 같다. 대부분 듀렛의 노테이션을 따랐지만 **Thm 2.2.6**에서만은 Chung의 기호를 빌려왔는데 그 이유는 듀렛책의 표현이 너무 간결하여 의미가 헷갈릴수도 있겠다 싶었기 때문이다.

Theorem 2.2.7.: (1)-(2) X_1, \dots, X_n 이 *i.i.d.*라고 하자. (3) $X_1 \dots X_n$ 이 아래의 모멘트 조건을 만족한다고 하자.

$$xP(|X_1| > x) \rightarrow 0 \text{ as } x \rightarrow \infty \quad \cdots (\tilde{\star})$$

아래의 WLLN이 성립한다.

$$\frac{X_1 + \cdots + X_n}{n} \xrightarrow{p} \tilde{\mu}^n \quad \text{where} \quad \tilde{\mu}^n := E(X_1 \mathbf{1}_{|X_1| \leq n}).$$

note: Thm 2.2.7.은 $\frac{X_1 + \cdots + X_n}{n}$ 의 p -수렴성은 보장하지만 그것이 $\mu = EX_1$ 로 수렴함을 보장하지 않는다. 즉

$$\frac{X_1 + \cdots + X_n}{n} \xrightarrow{p} \mu$$

임을 보장하는것은 아니다. 이게 성립하려면 $\tilde{\mu}^n \rightarrow \mu$ 가 성립해야 하고 이는 DCT에 의해서 성립해야하는데 DCT가 성립하려면 $E|X_i| < \infty$ 의 조건이 추가적으로 있어야 한다. (어디로인가 수렴한다고 했지 제 정신 밖인 값으로 수렴한다고는 안했다!!) 즉 **Thm 2.2.7**의 조건 아래에서

$$\frac{X_1 \mathbf{1}_{|X_1| \leq n} + \cdots + X_n \mathbf{1}_{|X_n| \leq n}}{n}, \quad \frac{X_1 + \cdots + X_n}{n}$$

모두 같은 p -극한을 가진다.

Theorem 2.2.9.: (1)-(2) X_1, \dots, X_n 이 *i.i.d.*라고 하자. (3) 유한평균값이 존재한다고 하자. 즉

$$E|X_i| < \infty$$

이라고 하자. 그러면 아래의 WLLN이 성립한다.

$$\frac{X_1 + \cdots + X_n}{n} \xrightarrow{p} \mu \quad \text{where} \quad \mu := EX_1.$$

4.1 증명들

Lemma 2.2.2의 증명

- 체비셰프 부등식을 이용하면 된다.

Theorem 2.2.3의 증명

- L_2 수렴함을 보이면 된다.

$$E\left(\frac{X_1 + \cdots + X_n}{n} - \mu\right) \leq \frac{Cn}{n^2} = o(1)$$

이므로 증명끝.

Theorem 2.2.4의 증명

- 역시 L_2 수렴함을 보이면 된다.

$$E\left(\frac{X_{n,1} + \cdots + X_{n,n}}{b_n} - \frac{\mu_{n,1} + \cdots + \mu_{n,n}}{b_n}\right) = b_n^{-2}V(X_{n,1} + \cdots + X_{n,n}) = o(1)$$

이므로 증명 끝.

Theorem 2.2.6의 증명

- 생략.

Theorem 2.2.7의 증명

- 증명을 위해서 아래의 레마를 외우자. 이걸 증명하는것보다 아래의 레마를 외우는게 더 중요하다.

Lemma 2.2.8.: $Y \geq 0$ 이고 $r > 0$ 이면 아래가 성립한다.

$$E(Y^r) = \int_0^\infty ry^{r-1}P(Y > y)dy.$$

note: 이 정리에서 Y 를 양의 확률변수로 한정 한 이유는 증명과정에서 푸비니정리를 쓰기 때문이다.

- 조건 $(\tilde{\star})$ 에서 $i.i.d.$ 를 쓰면 바로 (\star) 를 얻을수 있다. 우선 조건 $(\tilde{\star})$ 를 살펴보자.

$$(\tilde{\star}) : xP(|X_1| > x) = o(1) \quad \text{as } x \rightarrow \infty$$

x 대신에 n 을 대입하자.

$$nP(|X_1| > n) = o(1)$$

이제 *i.i.d.* 조건을 쓰면 아래를 얻을 수 있다.

$$\sum_{k=1}^n P(|X_k| > n) = nP(|X_1| > n) = o(1)$$

$X_{n,k} = X_k$ 라고 놓고 $b_n = n$ 이라고 두면 이것은 **Thm 2.2.6**의 셋팅에서 (\star) 를 보인셈이 된다.

- 이제 $(\star\star)$ 를 보이자. 즉 아래를 보이면 된다.

$$\begin{aligned} & b_n^{-2} \sum_{k=1}^n E \left(X_{n,k}^2 \mathbf{1}_{|X_{n,k}| \leq b_n} \right) \\ &= n^{-2} \sum_{k=1}^n E \left(X_k^2 \mathbf{1}_{|X_k| \leq n} \right) = n^{-2} n E \left(X_1^2 \mathbf{1}_{|X_1| \leq n} \right) \\ &= o(1). \end{aligned}$$

- $Y := X_1 \mathbf{1}_{|X_1| \leq n}$ 로 보고 **Lemma 2.2.8**을 쓰자. ²

$$E \left(X_1^2 \mathbf{1}_{|X_1| \leq n} \right) = EY^2 = \int_0^\infty 2yP(Y > y)dy$$

그런데 일단 $Y \leq n$ 이므로 $y \geq n$ 이라면 $P(Y > y) = 0$ 이다.³ 따라서 적분의 범위를 $[0, \infty]$ 에서 $[0, n]$ 으로 좁힐 수 있다. 즉

$$\int_0^\infty 2yP(Y > y)dy = \int_0^n 2yP(Y > y)dy$$

이다. 아래가 성립함을 관찰하라.

$$\int_0^n 2yP(Y > y)dy = \int_0^n 2yP(X_1 \mathbf{1}_{|X_1| \leq n} > y)dy \leq \int_0^n 2yP(X_1 > y)dy$$

따라서 아래를 보이면 증명이 끝난다.

$$\frac{1}{n} \int_0^n 2yP(X_1 > y)dy = o(1) \quad \text{or} \quad \int_0^n 2yP(X_1 > y)dy = o(n)$$

이 식은 직관적으로 성립함을 알 수 있다. 왜냐하면

$$2yP(X_1 > y) = o(1) \quad \text{as} \quad y \rightarrow \infty$$

² $Y := X_1 \mathbf{1}_{|X_1| \leq n}$ 이니까 당연히 $Y^2 = X_1^2 \mathbf{1}_{|X_1| \leq n}$ 인건 말안해도 괜찮겠지? $(\mathbf{1}_{|X_1| \leq n})^2 = \mathbf{1}_{|X_1| \leq n}$ 이니까?

³잘 모르겠으면 수직선 그려놓고 Y, n, y 순서로 그려봐

이고

$$\frac{1}{n} \int_0^n 2yP(X_1 > y)dy$$

는 $2yP(X_1 > y)$ 의 평균같은 개념이기 때문이다.

- 좀 더 엄밀하게 증명하기 위해서⁴ 아래를 주목하라.

$$0 \leq g(y) \leq 2y, \quad \text{where} \quad g(y) = 2yP(X_1 > y)$$

아래가 성립한다.

$$g(y) = o(1)$$

$o(1)$ 이면 $O(1)$ 이니까 아래가 성립한다.

$$\sup_y g(y) = M < \infty$$

아래를 정의하자.

$$\epsilon_K = \sup_{y>K} g(y)$$

그리고 $[0, K]$ 까지의 적분과 $[K, n]$ 까지의 적분을 따로 생각하자.⁵

$$\int_0^n 2yP(|X_1| > y)dy \leq KM + (n - K)\epsilon_K$$

양변을 n 으로 나누고 $n \rightarrow \infty$ 를 취하자. 그러면⁶

$$\limsup_{n \rightarrow \infty} \frac{1}{n} \int_0^n 2yP(|X_1| > y)dy \leq \epsilon_K$$

가 성립한다.⁷ K 가 arbitrary이고 $\epsilon_K \rightarrow 0$ as $K \rightarrow \infty$ 이므로 원하는 결론을 얻을 수 있다.⁸

note: 증명의 뒷부분의 논리를 좀 더 내 방식으로 해석해보자. 아래를 정의하자.

$$\epsilon_{K_n} = \sup_{y>K_n} g(y)$$

⁴to spell out the details
⁵consider A and B seperately
⁶Dividing by n and letting $n \rightarrow \infty$, we have
⁷굳이 \limsup 을 쓸 필요는 없어보인다. \lim 만 써도 충분한듯. 하지만 \limsup 으로 쓸 수 있어서 그냥 쓴 것 같다.
⁸ K 가 $K < n$ 인 조건하에서는 아무렇게나 선택할 수 있다는 의미는 (1) n 을 무한대로 보낼때 K 도 그에 맞춰서 무한대로 가면서 (2) $K/n \rightarrow 0$ as $n \rightarrow \infty$ 를 만족하도록 적당히 정할 수 있다는 의미이다. 이는 매우 **편리한** 성질이다. 풀이과정중 $\frac{KM}{n}$ 을 0으로 수렴시키게 할 수 있는것은 (2)의 성질을 이용한 것이다. 또한 $\epsilon_K = o(n)$ 임을 보일때 $\epsilon_K = o(K)$ 임을 대신 보여도 충분한 것은 (1)의 성질 때문이다.

여기에서 수열 K_n 은 아래의 성질을 만족한다.

$$\begin{cases} K_n < n & \text{for all } n \\ K_n \rightarrow \infty & \text{as } n \rightarrow \infty \\ \frac{K_n}{n} = o(1) & \text{as } n \rightarrow \infty \end{cases}$$

즉 $\{K_n\}$ 이 n 이 무한대로 갈때 그에 맞추어서 점점 무한대로 가는 (하지만 항상 $K_n < n$ 인) 어떠한 수열이다.⁹ 그리고 $[0, K_n]$ 까지의 적분과 $[K_n, n]$ 까지의 적분을 따로 생각하자.

$$\int_0^n 2yP(|X_1| > y)dy \leq K_n M + (n - K_n)\epsilon_{K_n}$$

양변을 n 으로 나누면

$$\frac{1}{n} \int_0^n 2yP(|X_1| > y)dy \leq \frac{K_n M}{n} + \epsilon_{K_n} - \frac{1}{n} = \epsilon_{K_n} + o(1) \quad \text{as } n \rightarrow \infty$$

와 같이 된다. 그런데

$$\epsilon_{K_n} = o(1) \quad \text{as } n \rightarrow \infty$$

이므로 증명이 끝난다.

note: 이제 어심토틱에 나오는 증명의 묘미이다. y 에 대한 극한조건을 교묘하게 n 혹은 K 대한 극한조건으로 바꾸어서 증명한다.

Theorem 2.2.9의 증명

- 확률변수가 유한평균값을 가지므로 아래가 성립한다.

$$(\tilde{\star}) : \quad xP(|X_1| > x) \rightarrow 0 \quad \text{as } x \rightarrow \infty$$

참고로 위의 식이 성립하는 이유는

$$xP(|X_1| > x) \leq E(|X_1| \mathbf{1}_{|X_1| > x}) \rightarrow 0$$

이기 때문이다. 왼쪽의 부등호는 적분꼴로 쓰면 바로 이해가능하고 오른쪽의 극한은 DCT에 의해서 성립한다. 아무튼 조건 (\star) 가 성립하므로 **Thm 2.2.7**을 쓰면

$$\frac{X_1 + \cdots + X_n}{n} \xrightarrow{p} \tilde{\mu}^n := E(X_1 \mathbf{1}_{|X_1| \leq n}) \quad \text{as } n \rightarrow \infty$$

⁹조건 $(\tilde{\star})$ 에 의해서 $\epsilon_{K_n} = o(1)$ as $n \rightarrow \infty$ 가 성립함

가 성립한다. 그런데 아래의 식이 성립한다. (DCT에 의해서 성립함)

$$\tilde{\mu}^n := E(X_1 1_{|X_1| \leq n}) \rightarrow \mu := EX_1 \text{ as } n \rightarrow \infty$$

이제 $S_n/n \xrightarrow{p} \tilde{\mu}^n$ 와 $\tilde{\mu}^n \rightarrow \mu$ 임을 이용하면 아래가 성립함을 알 수 있다. ($o_p(1) + o(1) = o_p(1)$ 이므로 성립.)

$$\frac{X_1 + \cdots + X_n}{n} \xrightarrow{p} \mu.$$

• 증명과정에서 기억할만한 것은 확률변수가 유한평균값을 가진다는 것이 아래를 임플라이 한다는 것이다.

$$(\tilde{*}) : \quad xP(|X_1| > x) \rightarrow 0 \quad \text{as } x \rightarrow \infty$$

반대로 위 조건(앞으로 편의상 조건 $(\tilde{*})$ 라고 부르자)이 유한평균값을 가짐을 임플라이 하지는 못한다. 따라서 조건 $(\tilde{*})$ 은 유한평균값을 가진다는 조건보다 약한 조건이다. 하지만 조건 $(\tilde{*})$ 은 확률변수가 유한평균값을 가진다는 조건보다 정말 말 그대로 ϵ 만큼만 약한 조건이다. 구체적으로는 조건 $(\tilde{*})$ 이 만족하면 아래를 임플лай 할 수 있다.

$$(\tilde{*}) \implies \forall \epsilon > 0 : E|X_1|^{1-\epsilon} < \infty$$

이것의 증명은 **Lemma 2.2.8**을 이용해서 할 수 있다. 따라서 조건 $(\tilde{*})$ 는 유한평균값을 가진다는 조건에 비하여 많이 부족한 조건은 아니다. 사실상 거의 대등하다고 보아도 무방하다.

note: 조건 $(\tilde{*})$ 와 *uniformly tight*를 헷갈렸었다. (진짜 아는게 없어서 오만걸 다 헷갈리네) 내가 헷갈린 타이트조건은 아래와 같이 쓸 수 있다.

$\{X_n\}$ is *uniformly tight*

$$\stackrel{def}{\iff} \forall \epsilon > 0 \quad \exists M \quad \text{s.t.} \quad \sup_n P(|X_n| > M) < \epsilon$$

$$\stackrel{def}{\iff} \sup_n P(|X_n| > M) \rightarrow 0 \quad \text{as } M \rightarrow \infty$$

$$\stackrel{def}{\iff} \sup_n \mu_n^*([-M, M]^c) \rightarrow 0 \quad \text{as } M \rightarrow \infty$$

$$\stackrel{def}{\iff} \epsilon > 0 \quad \exists M \quad \text{s.t.} \quad \limsup_{n \rightarrow \infty} (1 - F_n(M) + F_n(-M)) < \epsilon$$

$$\stackrel{def}{\iff} X_n = O_p(1) \quad \text{as } n \rightarrow \infty$$

note: 보통 유니폼리-타이트니스도 그냥 줄여서 타이트니스라고 말하기도 한다.

note: 모든 확률변수는 *tight*하다.¹⁰ 하지만 모든 확률변수열이 *uniformly tight*하지는 않다.¹¹

5 Borel-Cantelli Lemmas

5.1 set-theory

- 듀렛교재와 더불어 인터넷을 참고해보자.¹²

$$(1) \sup_{k \geq n} A_k = \bigcup_{k=n}^{\infty} A_k. \quad ^{13}$$

$$(2) \inf_{k \geq n} A_k = \bigcap_{k=n}^{\infty} A_k.$$

$$(3) \limsup_{n \rightarrow \infty} A_n = \lim_{n \rightarrow \infty} \sup_{k \geq n} A_k = \lim_{n \rightarrow \infty} \bigcup_{k=n}^{\infty} A_k = \bigcap_{n=1}^{\infty} \bigcup_{k=n}^{\infty} A_k. \quad ^{14}$$

$$(4) \liminf_{n \rightarrow \infty} A_n = \lim_{n \rightarrow \infty} \inf_{k \geq n} A_k = \lim_{n \rightarrow \infty} \bigcap_{k=n}^{\infty} A_k = \bigcup_{n=1}^{\infty} \bigcap_{k=n}^{\infty} A_k.$$

- A_n 이 Ω 의 부분집합으로 이루어진 집합열이라고 한다면, 아래와 같이 둘 수 있다.¹⁵

$$(1) \limsup_{n \rightarrow \infty} A_n = \left\{ \omega \in \Omega : \sum_{n=1}^{\infty} I(\omega \in A_n) = \infty \right\} = \left\{ \omega : \omega \in A_n, i.o. \right\}$$

$$(2) \liminf_{n \rightarrow \infty} A_n = \left\{ \omega \in \Omega : \sum_{n=1}^{\infty} I(\omega \in A_n) < \infty \right\} = \left\{ \omega : \omega \in A_n, a.b.f. \right\}$$

¹⁰타이트의 정의는 아래와 같다.

The random variable X is *tight*

$$\stackrel{def}{\iff} \forall \epsilon > 0 \quad \exists M \quad s.t. \quad P(|X| > M) < \epsilon$$

$$\stackrel{def}{\iff} P(|X| > M) \rightarrow 0 \quad as \quad M \rightarrow \infty$$

$$\stackrel{def}{\iff} \mu^*([-M, M]^c) \rightarrow 0 \quad as \quad M \rightarrow \infty$$

$$\stackrel{def}{\iff} \epsilon > 0 \quad \exists M \quad s.t. \quad 1 - F(M) + F(-M) < \epsilon$$

¹¹확률변수열이 *uniformly tight*하다는 말은 확률변수열이 유계라는 말과 같다. Van der Vaart (2000)의 p.8.

¹²[1] http://theanalysisofdata.com/probability/A_4.html, [2] https://en.wikipedia.org/wiki/Set-theoretic_limit

¹³여기에서 $\sup_{k \geq n} A_k$ 는 sequence of n 임을 유의하자. 즉 $\sup_{k \geq n} A_k = B_n$ 과 같이 놓을 수 있다. 하지만 k 에 대한 sequence는 아니기 때문에 $\sup_{k \geq n} A_k = B_k$ 와 같이 놓을 수는 없다.

¹⁴마지막등호는 $\bigcup_{k=n}^{\infty} A_k := B_n$ 이 n 에 대한 monotone sequence이기 때문에 성립한다.

¹⁵If A_n is subset of sequence of Ω , we let

example: X_1, X_2, \dots 이 베르누이열이라고 하자. ¹⁶ 그리고 $(\Omega_1, \mathcal{F}_1, P_1)$ 을 X_1 에 대응하는 확률공간이라고 하자. 콜모고로프정리에 따라서 랜덤벡터 (X_1, X_2, \dots) 가 정의되는 공간 (Ω, \mathcal{F}) 를 정의할 수 있다. ¹⁷ 이제 $S_n/b_n = \frac{1}{n} \sum_{i=1}^n X_i$ 라고 하자. 이제

$$A_n = \left\{ \omega \in \Omega : |S_n(\omega)/b_n - 1/2| > \epsilon \right\}$$

라고 정의하자. ¹⁸ 그러면

$$\sup_{\epsilon > 0} \left\{ \limsup_{n \rightarrow \infty} A_n \right\} = \left\{ 0 \text{보다 } 1 \text{의 숫자가 일정한 비율로 많은 모든 이벤트} \right\}$$

이다.

note: $\sup_{\epsilon > 0} \left\{ \limsup_{n \rightarrow \infty} A_n \right\}$ 의 원소로 어떤것이 있을지 알아보자. 빨간색글자는 copy and paste 로 반복된다고 하자.

$$(1) : \{ 1, \mid \textcolor{red}{1}, 0, \mid \textcolor{red}{1}, 0, \mid, \dots \}$$

$$(2) : \{ 1, 1, \mid \textcolor{red}{1}, 0, \mid \textcolor{red}{1}, 0, \mid, \dots \}$$

$$(3) : \{ 1, 1, 1, \mid \textcolor{red}{1}, 0, \mid \textcolor{red}{1}, 0, \mid, \dots \}$$

$$(4) : \{ \overbrace{1, \textcolor{red}{1}, 0, 1, 0, 1, 0, 1, 0, \dots, 1, 0}^{\times 100}, \mid \overbrace{1, \textcolor{red}{1}, 0, 1, 0, 1, 0, 1, 0, \dots, 1, 0}^{\times 100}, \mid, \dots \}$$

(1)-(3)의 경우는 $\sup_{\epsilon > 0} \left\{ \limsup_{n \rightarrow \infty} A_n \right\}$ 의 원소이지만 (4)의 경우는 아니다.¹⁹

6 Poisson Convergence

Theorem: Each n 에 대하여 $X_{n,m}$, $1 \leq m \leq n$ 이 서로 독립인 확률변수라고 하자. 그리고 $P(X_{n,m} = 1) = p_{n,m}$ 이고 $P(X_{n,m} = 0) = 1 - p_{n,m}$ 이라고 하자.

(1) $\sum_{m=1}^n p_{n,m} \rightarrow \lambda$ as $n \rightarrow \infty$ (2) $\max_{1 \leq m \leq n} p_{n,m} \rightarrow 0$ as $n \rightarrow \infty$ 이라면 아래가 성립한다.

$$S_n \Rightarrow Z \quad \text{where } Z \text{ is Poisson}(\lambda).$$

¹⁶즉 X_1, X_2, \dots 의 가능한 realization은 $0, 1, \dots$ 이다.
¹⁷즉 $\Omega := \Omega_1 \times \Omega_2 \times \dots$ 이고 $\mathcal{F} := \mathcal{F}_1 \times \mathcal{F}_2 \times \dots$.
¹⁸ A_n 은 ϵ 에 따라 변화하는 함수인데 이를 강조하기 위해서 $A_n(\epsilon)$ 이라고 표시할 수도 있다.
¹⁹왜냐하면 (4)의 경우는 $\epsilon = \frac{1}{101}$ 보다 크면 $\limsup_{n \rightarrow \infty} A_n$ 의 원소이지만 $\epsilon = \frac{1}{101}$ 보다 작으면 $\limsup_{n \rightarrow \infty} A_n$ 의 원소가 아니기 때문이다.

note: 이항분포의 포아송근사. 일단 독립인 랜덤변수들의 합의 분포를 다루는 것임.

6.1 Two Example with Dependence

- 독립이 아닌경우에서도 포아송으로 근사할 수 있다는 예제들을 설명한 챕터인 듯.

7 Limit Theorems in \mathbb{R}^d

exercise: F_1, \dots, F_d 가 \mathbb{R} 에서 정의되는 distribution이라고 하자. ²⁰ 그러면 임의의 $\alpha = [-1, 1]$ 에 대하여

$$F(x_1, \dots, x_d) = \left\{ 1 + \alpha \prod_{i=1}^d (1 - F_i(x_i)) \right\} \prod_{j=1}^d F_j(x_j)$$

역시 d.f. 이고 $F(x_1, \dots, x_d)$ 의 마지날은 각각 F_1, \dots, F_d 와 같다. 이때 $\alpha = 0$ 은 $\mathbf{X} = (X_1, \dots, X_d)^\top$ 의 각 원소가 독립인 경우를 의미한다.

²⁰Let F_1, \dots, F_d be the distributions on \mathbb{R} .